

이상 점수 임계값 선택 기준에 따른 비지도 이상치 탐지 방법의 성능 분석

전장군*, 이상민**, 김남기***

경기대학교 전자공학과*, 경기대학교 AI컴퓨터공학부**, ***

201812285@kyonggi.ac.kr, d9249@kyonggi.ac.kr, ngkim@kyonggi.ac.kr

Analysis of performance of unsupervised anomaly detection methods according to anomaly score threshold selection criteria

Jeon Janggun*, Lee Sangmin**, Kim Namgi**

1. 소 개

이상 현상은 작업환경에서 정상적으로 여겨지지 않은 결과들을 말하며, 이상 탐지란 작업환경의 여러 attributes를 분석해 이상 현상을 감지하는 방법에 대한 연구분야이다 [5]. 이상 탐지 연구는 많은 종류의 새로운 어플리케이션이나 플랫폼들이 등장하고, 기계학습 기술이 발전하면서 현재 활발히 연구되고 있다.

최근까지 연구된 이상 탐지 방법론들은 데이터에서 특징을 추출하고 학습하여 이상 점수를 도출하고, 적절한 임계값을 기준으로 이상 점수와 비교하여 이상 여부를 판단하는 구조를 공통적으로 가지고 있다 [1]. 여기서 적절한 임계값을 선택하는 방법은 기존에 여러 가지가 있지만, 각각 단점들이 존재한다.

따라서, 본 논문에서는 이상 점수와 비교하여 이상 여부를 판단하기 위한 임계값 선택 방법을 새롭게 제시한다. 본 논문에서는 제시한 임계값 선택 방법의 유효성을 검증하기 위해서, 기존의 임계값 선택 방법과의 비교 실험을 진행하였다.

실험을 위한 이상 탐지 모델은 다른 관련 연구들에 기여할 수 있도록 비지도 방식의 모델을 사용하였다. 왜냐하면, 이상 데이터를 구하기 어려운 점과 라벨에 대한 비용 때문에 많은 이상 탐지 연구는 비지도 방식 방법론에 중점을 두는 이유가 있다. 그래서, 실험을 위해 이상 점수를 도출하는 모델은 전통적인 기계학습 방법 중 하나인 Isolation Forest(IF) 알고리즘 [4]과 신경망 기반 딥러닝 방식의 모델인 USAD(UnSupervised Anomaly Detection) 아키텍처 [2]를 사용한다.

2. 관련 연구

IF 알고리즘은 격리 기반 방식의 비지도 이상 탐지 방법이다. IF는 딥러닝이 아닌 비모수적인 방법들 중 선형시간 복잡도를 가지고 고차원 데이터에 적용될 수 있기 때문에 [6] 비교 모델로써 채택했다. USAD 아키텍처는 AE-GAN 계열의 비지도 딥러닝 방식의 모델이다. AE-GAN 계열 아키텍처는 비지도 방식의 딥러닝 방법들 중 이상 탐지 분야에 적용하기 위해 관심을 받고 있는 AE [3]와 GAN [7]계열 모델들의 장점이 합쳐진 모델이다.

이상 탐지 방법론은 데이터 세트의 특성에 따라, 비모수적인 방법과 딥러닝 방법 중 적합한 것이 다르기 때문에, 비교대상으로 적절한 두 모델을 실험 모델로 선정한다.

3. 본 론

일반적인 이상 탐지 연구에서 성능 평가를 위해 사용되는 항목으로는 Precision(P), Recall(R), P와 R의 조화평균인 F1 score(F1)가 있다. 각 항목에 대한 정의는 다음과 같다.

$$P = \frac{TP}{TP + FP}, R = \frac{TP}{TP + FN}, F1 = 2 \times \frac{P \times R}{P + R}$$

위의 평가항목을 계산하기 위해서는 이상 탐지 모델이 도출한 이상 점수를 분석하여 임계값 선택 과정이 필요하다.

임계값 선택 방법으로는 여러 가지 기준이 존재한다. 우선, 기본적으로 가능한 모든 임계값 중 F1이 가장 높은 임계값을 선택하는 기준이 있다. 그러나, 실험 데이터 세트에서 positive 샘플과 negative 샘플의 개수가 많이 차이가 나면 좋지 않다. 예를 들어, positive 샘플이 98개이고 negative 샘플이 2개일 때, 모든 샘플이 positive로 판단되는 임계값을 선택하면 F1은 0.9898이다. 반면, negative 샘플 관점에서 모든 샘플에 대해 정답률이 0.0이다. 그래서 이 방법은 적절하다 볼 수 없다.

일반적인 논문들에서는 positive 샘플에 대한 정확도인 TPR과 negative 샘플에 대한 정확도인 TNR이 같을 때의 임계값을 선택하는 방법을 사용한다.

$$TPR = R = \frac{TP}{TP + FN}, TNR = \frac{TN}{TN + FP}$$

그러나, 음의 상관관계인 TPR과 TNR이 일치할 때, 항상 최적의 trade-off를 가진다 볼 수 없다.

TPR과 TNR이 선형 반비례 관계일 경우, TPR과 TNR의 조화평균이 최대값을 가지며 최적의 trade-off를 찾았다 볼 수 있다. 하지만, 일반적으로 TPR과 TNR은 비선형 반비례 관계를 가지기 때문에, 이 방법은 최적의 임계값 선택 기준이라 볼 수 없다.

따라서, 본 논문에서는 TPR과 TNR의 조화평균이 최대값을 가지는 순간의 임계값을 선택하는 방법을 제안하며, 이 선택 기준이 더 최적에 가깝다고 판단한다. 본 논문에서 제시하는 임계값 선택 방법은 이후에 실험을 통해 그 성능을 보여주고 있다.

4. 실험

본 논문에서는 비모수 방식의 IF 모델, AE-GAN 계열 USAD 모델들에 대해 비교실험을 진행한다. 성능 비교를 위해 적절한 기준을 위해, USAD와 IF가 모두 사용된 참조 논

문 [2]의 공개된 실험에서 쓰인 데이터 세트를 사용하였다.

실험에서 사용된 이상 탐지 데이터 세트는 Soil Moisture Active Passive(SMAP)로, 화성 토양 수분 데이터를 모니터링해 전문가가 라벨링하였다.

Threshold: harmonic mean maximum		
metrics	IF	USAD
P	0.9557	0.9478
R	0.8813	0.9034
F1	0.9170	0.9251

Threshold: TPR and TNR same value		
metrics	IF	USAD
P	0.9560	0.9437
R	0.7517	0.7002
F1	0.8416	0.8039

(표 1) 성능 비교 실험 결과

실험 결과는 표 1에 나타난다. IF와 USAD 방법 모두 모두 향상된 성능을 보여주고 있다. 또한, 성능 향상 수치가 USAD가 더 높은 것을 보고, TPR과 TNR이 일치할 때와 TPR과 TNR의 조화평균이 최대일 때의 임계값 차이가 더 크다고 판단할 수 있다.

5. 결 론

본 논문에서는 이상 탐지 방법의 성능 평가를 위해, 기존의 이상 점수와 비교할 임계값 선택 기준을 새롭게 제시했으며, 실험을 통해 제안한 임계값 선택 방식의 유효성은 증명되었다. 추가적으로, 기존의 방식과 제안한 방식을 적용했을 때 선택되는 임계값의 차이가 모델간 성능 우열관계를 다르게 했다는 점에서 임계값 선택 방법의 중요성을 재확인 할 수 있다.

ACKNOWLEDGMENT

본 논문은 교육부의 재원으로 한국연구재단의 지원(NRF-2020R1A6A1A03040583)과 과학기술정보통신부 및 정보통신기획 평가원의 SW중심대학지원사업(2021-0-01393)의 연구결과로 수행되었음

참 고 문 헌

- [1] Pang, Guansong, et al. "Deep learning for anomaly detection: A review." *ACM computing surveys (CSUR)* 54.2 (2021): 1-38.
- [2] Audibert, Julien, et al. "Usad: Unsupervised anomaly detection on multivariate time series." *Proceedings of the 26th ACM SIGKDD international conference on knowledge discovery & data mining* . 2020.
- [3] David E. Rumelhart, Geoffrey E. Hinton, and Ronald J. Williams. 1986. Learning Internal Representations by Error Propagation. MIT Press, Cambridge, MA, USA, 318 - 362.
- [4] Liu, Fei Tony, Kai Ming Ting, and Zhi-Hua Zhou. "Isolation forest." *2008 eighth ieee international conference on data mining* . IEEE, 2008.
- [5] Frank E Grubbs. 1969. Procedures for detecting outlying observations in samples. *Technometrics* 11, 1 (1969), 1 - 21.

- [6] Liu, Fei Tony, Kai Ming Ting, and Zhi-Hua Zhou. "Isolation-based anomaly detection." *ACM Transactions on Knowledge Discovery from Data (TKDD)* 6.1 (2012): 1-39.
- [7] Ian J. Goodfellow, Jean Pouget-Abadie, Mehdi Mirza, Bing Xu, David WardeFarley, Sherjil Ozair, Aaron C. Courville, and Yoshua Bengio. 2014. Generative Adversarial Nets. In *Advances in Neural Information Processing Systems 27: Annual Conference on Neural Information Processing Systems 2014*. Montreal, Quebec, Canada, 2672 - 2680