

GNN 기반 딥러닝 모델에서 시간-공간 Attention 모듈 구조에 따른 교통 흐름 예측 성능 분석

전장군*, 이상민**, 김남기***

*경기대학교 전자공학과, **, ***경기대학교 AI컴퓨터공학부

201812285@kyonggi.ac.kr, d9249@kyonggi.ac.kr, ngkim@kyonggi.ac.kr

Analysis of Traffic Flow Prediction Performance According to Spatial-Temporal Attention Module Structures in GNN-based Deep Learning Model

Jeon Janggun*, Lee Sangmin**, Kim Namgi***

*Dept. of Electric Engineering Kyonggi Univ.,

, *Dept. of AI Computer Engineering Kyonggi Univ.

요 약

본 논문에서는 딥러닝을 이용한 교통 흐름 예측(traffic flow prediction)[1] 시스템에 대해 간단히 설명하고, 그 래프 타입 시계열 교통 데이터에 대한 딥러닝 예측 모델들에 대해서 소개한다. 그리고, 딥러닝 예측 모델들 중 ASTGNN[2] 모델의 자세한 설명과 ASTGNN에서 교통 데이터의 시공간적 특성처리 역할을 하는 Spatial-Temporal Attention Module(시간-공간 Attention 모듈)의 직렬 방식 구조와 병렬 방식 구조에 대한 성능을 분석한다. 그리고 분석결과, 병렬 방식 구조의 이점에 대해 설명한다.

1. 서 론

최근, 여러가지 사회-경제적 이유로 ITS(지능형 교통 시스템)[3]의 개발이 요구되고 있다. 교통 데이터에 대한 예측된 정보를 통해서, 정부기관은 미래의 교통상황에 대한 관리계획을 효율적으로 수립할 수 있고, 시민은 제공되는 교통정보를 바탕으로 일간 교통경로 선택에 대한 실질적인 도움을 받을 수 있다. ITS 개발에서 핵심적인 부분은 교통 흐름 예측[1]으로, 과거부터 현재까지 관측된 도로 교통량 정보를 이용하여, 미래의 교통량을 예측하는 시스템이다. 교통 흐름 예측을 위해 사용되는 데이터는, 그 특성상 그래프 형식의 시계열 데이터로 이루어져 있다. 그래서, 대부분의 연구들은 GNN(Graph Neural Network) Model을 기반으로 한 딥러닝 방법론이 많이 연구되고 있다. 본 논문에서도 GNN model을 기반으로, 교통 데이터의 시간적-공간적 특성을 잘 처리하기 위해 Spatial-Temporal Attention Module을 서로 다른 방식으로 적용한 모델들의 성능을 실험을 통해 비교 분석한다.

2. 관련 연구


교통 흐름 예측에서 초기연구는 VAR[4]과 같은 선형 시계열 분석에 기반한 방법들이 사용되었다. 그러나 그래프 타입 데이터에서 노드들간의 상호연관성은 비선형적인 특성들 또한 포함하기 때문에, 선형 시계열 분석에 기반한 연구방법들은 효과적이지 못했다. 그 후에 딥러닝을 기반으로 비선형적인 특성들 또한 분석할 수 있도록 연구가 진행되었는데, 그중에 초반에 제안된 것이 CNN(Convolutional Neural Network) 기반 모델들을 이용한 방법들이다. 하지만 결과적으로, CNN 기반 방법들은 교통 데이터의 도로망들의 연결로 인한 특성을 처리하는 데 어려움을 겪었다. 그래서, 교통 데이터의 도로망과 같은 그래프 타입의 데이터를 처리하는데 적합한 GNN 기반의 모델링 방법이 현재까지 연구되고 있다. 특히, 본 논문은 GNN 기반으로 GCN(Graph Convolutional network)이나 Spatial-Temporal Attention Module을 적용해서, 그래프 시퀀스

들에 대한 주기성과 노드들간에 상호작용을 포착하는 ASTGNN[2], ASTGCN[5], PDFormer[6] 모델들을 참고한 2가지 방식의 모델 구조들을 사용한다.


3. 본론

최신 연구결과, 교통 흐름 예측에서 저널 심사를 거친 논문들의 모델들중 가장 성능이 좋은 것은 ASTGNN[2]이다. ASTGNN은 트랜스포머(Transformer)와 유사한 구조의 GNN 모델이다. ASTGNN은 크게, 반복되는 인코더 레이어(Encoder layer)로 구성된 인코더(Encoder)와 반복되는 디코더 레이어(decoder layer)로 구성된 디코더(decoder)로 구성된다. 인코더 레이어와 디코더 레이어는 공통적으로 그래프들의 시퀀스에 대해서, 시간적 주기성을 temporal self-attention module로 처리하고, 공간적 노드들간 상호연관성을 single-head attention이 적용된 GCN 연산을 통해 처리한다. 그렇게 인코더로 시간적-공간적 특성이 처리된 데이터를 디코더 레이어의 temporal multi-head attention의 attention 연산에서 key와 value로 사용한다[2][5]. 여기서 인코더 입력을 시간적으로 과거의 교통 데이터를 주고, 디코더 입력을 시간적으로 미래의 교통 데이터로 주면, 디코더는 과거의 교통 데이터를 참고해서 미래의 교통 데이터를 예측하는 일을 할 수 있다. 트랜스포머와 유사하게 디코더의 출력을 다시 입력으로 주어서 미래의 교통데이터의 연속적인 시퀀스를 얻을 수 있다. 여기까지가 ASTGNN에 대한 설명인데, 저널 심사를 거치지 않은 비공식 연구자료[5][6][7] 중에서 ASTGNN 보다 좋은 성능을 보인 모델들이 존재한다. 이들의 공통점으로는 spatial attention 모듈과 temporal attention 모듈의 출력을 concatenate 시켜서, 교통 데이터의 시간적인 특성과 공간적인 특성을 동시에 처리하는 점이 있다. 본 논문에서는 이 방식을 병렬 방식이라 정의 하며, 그림 1과 같은 구조이다. 또

한, 기존의 ASTGNN의 방식을 직렬 방식이라 정의하며, 그림 2와 같은 구조이다. 이러한 병렬 방식을 temporal self-attention 모듈과 single-head attention이 적용된 GCN에 대해 적용한 구조의 모델과, 기존의 ASTGNN 직렬 방식 구조 적용 모델에 대해 비교 실험을 진행하였다.



(그림 1) (병렬 방식 구조)



(그림 2) (직렬 방식 구조)

3. 실험

본 실험은 표 1과 같은 데이터를 사용하여 진행하였다.

(표 1) (실험 데이터 정보)

Dataset		PEMS08
Graph shape	node	170
	edge	295
Time range		2016.07.01~2016.08.31

(표 2) (성능 실험 결과)

Model	MAE	RMSE	MAPE(%)
Serial	12.94 ± 0.08	22.90 ± 0.11	8.88 ± 0.11
Parallel	12.88 ± 0.08	22.73 ± 0.05	8.93 ± 0.04

실험결과는 표 2에 나타난다. 절대오차에 해당하는 MAE, RMSE 평가지표로 성능을 분석했을 때는 병렬 방식 구조의 모델이 우수했고, 상대오차에 해당하는 MAPE 평가지표로 성능을 분석했을 때는 직렬 방식 구조의 모델이 더 괜찮았지만, MAPE는 실제값에 대한 예측오차의 비율로, 실제값이 0에 가까운 작은 값일 경우 오차가 크게 나타난다. 결과를 해석하면, 병렬 방식 구조의 모델이 전체적으로 정확도가 높지만, 교통 흐름이 적은 순간에 노드의 흐름을 예측할 때는 직렬 방식 구조의 모델이 부분적으로 좋다고 볼 수 있다. 하지만, 이것은 교통 흐름 예측에서 일반적으로 사용되는 직렬 방식 구조의 모델이 전체적인 예측오차가 병렬 방식 구조의 모델보다 우수하지 않다는 의미이다.

4. 결론

교통 흐름 예측과 같은 주제로 시계열 그래프 데이터를 다룰 때는, 시간에 관한 주기성과 공간에 관한 상호연관성을 처리해야한다. 이러한 두 특성들 간의 비선형적인 관계를 동시에 처리하는 병렬 방식 Attention 모듈은 이 문제를 좀 더 잘 해결한다고 볼 수 있다. 이것은 또한, 두 개의 이질적인 시간-공간적 특성이 서로 완전히 독립적이지 않다고 판단할 수 있다.

ACKNOWLEDGMENT

본 논문은 교육부의 재원으로 한국연구재단의 지원(NRF-2020R1A6A1A03040583)과 경기도에서 지원하는 경기도지역 협력연구센터(GRRC)사업의 결과로 수행되었음

참고 문헌

- [1] Tedjopurnomo, D. A.; Bao, Z.; Zheng, B.; Choudhury, F. M.; and Qin, A. K. 2022. A Survey on Modern Deep Neural Network for Traffic Prediction: Trends, Methods and Challenges. *IEEE Trans. Knowl. Data Eng.*, 34(4): 1544–1561.
- [2] Guo, S., Lin, Y., Wan, H., Li, X., & Cong, G. (2021). Learning dynamics and heterogeneity of spatial-temporal graph data for traffic forecasting. *IEEE Transactions on Knowledge and Data Engineering*, 34(11), 5415–5428.
- [3] Yin, C.; Xiong, Z.; Chen, H.; Wang, J.; Cooper, D.; and David, B. 2015. A literature survey on smart cities. *Sci. China Inf. Sci.*, 58(10): 1–18.
- [4] Z. Lu, C. Zhou, J. Wu, H. Jiang, and S. Cui, “Integrating g-ranger causality and vector auto-regression for traffic prediction of large scale w lans.” *KSII Transactions on Internet & Information Systems*, vol. 10, no. 1, 2016.
- [5] Shengnan Guo, Youfang Lin, Ning Feng, Chao Song, Huaiyu Wan(*). Attention Based Spatial-Temporal Graph Convolutional Networks for Traffic Flow Forecasting. The 33rd AAAI Conference on Artificial Intelligence (AAAI’19) 2019.
- [6] Jiang, J., Han, C., Zhao, W. X., & Wang, J. (2023). PDFormer: Propagation Delay-aware Dynamic Long-range Transformer for Traffic Flow Prediction. *arXiv preprint arXiv:2301.07945*.
- [7] Zhu, W., Sun, Y., Yi, X., & Wang, Y. (2022). A Correlation Information-based Spatiotemporal Network for Traffic Flow Forecasting. *arXiv preprint arXiv:2205.10365*.